



**WYDZIAŁ FIZYKI
i INFORMATYKI STOSOWANEJ**
Uniwersytet Łódzki

Mateusz Matusiak

Kierunek: informatyka

Specjalność: technologie internetowe ???

Specjalizacja:

Numer albumu: 0288782

wpisać, jeżeli jest specjalizacja

Algorytm do analizy wad kręgosłupa odcinka lędźwiowego na podstawie obrazów DICOM

Praca magisterska

wykonana pod kierunkiem
dr Łukasza Albiniaka
w Katedrze Fizyki Stosowanej
WFiIS UŁ

Opiekun pracy:

dr Małgorzata Zielińska
Katedra Fizyki Stosowanej WFiIS UŁ

Łódź 2025

Spis treści

1	Wstęp	2
1.1	Temat pracy	2
1.2	Znaczenie problemu	3
1.3	Obrazowanie medyczne i przetwarzanie danych	4
2	Algorytm diagnozowania skoliozy	5
2.1	Opis	5
2.2	Założenia funkcjonalne i nefunkcjonalne	7
2.3	Metodka i opis algorytmu	9
2.3.1	Wyznaczenie szkieletu kanału kręgowego	9

1. Wstęp

1.1. Temat pracy

Tematem niniejszej pracy magisterskiej jest opracowanie oraz analiza działania algorytmów służących do oceny badań obrazowych odcinka lędźwiowego kręgosłupa. Dane wejściowe dla opracowanych metod stanowi segmentacja kręgosłupa w obrębie odcinka lędźwiowego, natomiast rezultatem jest klasyfikacja przypadku jako zdrowego lub patologicznego. Implementacja algorytmów została przeprowadzona w języku Python z wykorzystaniem specjalistycznych bibliotek dedykowanych przetwarzaniu obrazów medycznych.

Wybór tematu pracy podyktowany jest dużą częstością występowania schorzeń odcinka lędźwiowego kręgosłupa w populacji ogólnej. Dolegliwości bólowe w tym obszarze należą do najczęściej zgłaszanych problemów zdrowotnych, które istotnie obniżają jakość życia pacjentów i generują wysokie koszty leczenia. Współczesna medycyna wykorzystuje w diagnostyce zaawansowane metody obrazowania, takie jak rezonans magnetyczny (MRI) czy tomografia komputerowa (CT). Wygenerowane w ten sposób obrazy w formacie DICOM zawierają jednak ogromną ilość danych, których analiza wymaga odpowiedniego przygotowania i specjalistycznej wiedzy.

Automatyczna analiza obrazów medycznych stanowi dynamicznie rozwijającą się dziedzinę, której celem jest wspieranie lekarzy w procesie diagnostycznym. Jednym z kluczowych etapów tego procesu jest segmentacja struktur anatomicznych, umożliwiającą dalszą obróbkę i analizę danych. W przypadku kręgosłupa lędźwiowego poprawnie przeprowadzona segmentacja pozwala na wyodrębnienie interesującego obszaru i stanowi podstawę do opracowania algorytmów klasyfikacyjnych.

Celem głównym pracy jest zaprojektowanie, implementacja oraz analiza skuteczności algorytmów służących do klasyfikacji badań odcinka lędźwiowego kręgosłupa jako zdrowych lub patologicznych. Cele szczegółowe obejmują:

- przygotowanie i wstępne przetwarzanie danych obrazowych,
- opracowanie różnych podejść algorytmicznych do klasyfikacji przypadków,
- porównanie wyników uzyskanych metod pod kątem skuteczności, stabilności i praktycznej przydatności,

ocenę możliwości wykorzystania zaproponowanych rozwiązań w procesie diagnostycznym.

Znaczenie praktyczne niniejszej pracy wiąże się z rosnącą potrzebą tworzenia narzędzi wspierających pracę specjalistów w dziedzinie radiologii. Automatyczne lub półautomatyczne systemy mogą nie tylko skrócić czas analizy obrazów, ale również zmniejszyć ryzyko błędu ludzkiego.

Praca została zrealizowana w języku Python, wykorzystując dedykowane biblioteki do przetwarzania obrazów (m.in. SimpleITK, scikit-image, NumPy) oraz narzędzia wspomagające implementację i analizę algorytmów klasyfikacyjnych.

1.2. Znaczenie problemu

Kręgosłup człowieka stanowi główną oś szkieletu i pełni kluczowe funkcje w organizmie. Zbudowany jest z 24 kręgów podzielonych na odcinki: szyjny, piersiowy, lędźwiowy, krzyżowy, guziczny. Odcinek lędźwiowy składa się z pięciu największych i najmocniejszych kręgów, które odpowiadają za utrzymanie znacznej części ciężaru ciała oraz odpowiadają za wykonywanie szerokiego zakresu ruchów w płaszczyźnie strzałkowej. Ze względu na swoje położenie i funkcje odcinek ten jest szczególnie narażony na przeciążenie mechaniczne, urazy oraz procesy degeneracyjne.

Patologie odcinka lędźwiowego mogą mieć zróżnicowany charakter – od zmian zwyrodnieniowych i przepuklin dysków międzykręgowych, poprzez zwężenia kanału kręgowego, aż po wady wrodzone czy zmiany pourazowe. Wczesne wykrycie nieprawidłowości ma kluczowe znaczenie, ponieważ szybka diagnoza i odpowiednie leczenie pozwalają ograniczyć postęp choroby, zmniejszyć nasilenie objawów bólowych, a także poprawić rokowania pacjenta. Brak szybkiej interwencji może prowadzić do przewlekłego bólu, ograniczenia mobilności, a nawet trwałej niepełnosprawności.

Skala problemu jest znacząca zarówno w Polsce, jak i na świecie. Według danych Światowej Organizacji Zdrowia (WHO) bóle krzyża należą do najczęściej występujących dolegliwości układu mięśniowo-szkieletowego, a w ciągu życia doświadczą ich nawet 70–80% populacji. Schorzenia kręgosłupa są jedną z głównych przyczyn absencji w pracy oraz ograniczenia aktywności zawodowej. W Polsce, jak wskazują raporty Narodowego Funduszu Zdrowia, choroby związane z odcinkiem lędźwiowym stanowią jedną z najczęstszych przyczyn konsultacji ortopedycznych i neurologicznych. Szacuje się, że co

roku setki tysięcy pacjentów wymagają diagnostyki obrazowej tego obszaru, głównie w postaci rezonansu magnetycznego (MRI) oraz tomografii komputerowej (CT).

Rosnąca liczba przypadków, starzenie się społeczeństwa oraz coraz większe obciążenia związane ze współczesnym stylem życia (praca siedząca, brak aktywności fizycznej, otyłość) sprawiają, że problem schorzeń kręgosłupa lędźwiowego staje się jednym z kluczowych wyzwań współczesnej medycyny. Z tego względu poszukiwanie nowych metod wspierających proces diagnostyczny, w tym narzędzi automatyzujących analizę obrazów medycznych, nabiera szczególnego znaczenia. Rozwiązania te mogą nie tylko przyspieszyć wykrycie patologii, ale również odciążyć specjalistów, umożliwiając im skupienie się na najbardziej wymagających przypadkach klinicznych.

Wybór problematyki odcinka lędźwiowego w niniejszej pracy magisterskiej jest zatem uzasadniony zarówno ze względów klinicznych, jak i społecznych. Opracowanie i analiza algorytmów klasyfikacyjnych opartych na danych obrazowych może przyczynić się do poprawy jakości diagnostyki oraz stworzyć podstawę do dalszego rozwoju systemów wspomagania decyzji medycznych w radiologii.

1.3. Obrazowanie medyczne i przetwarzanie danych

Dynamiczny rozwój metod obrazowania medycznego w ostatnich dekadach przyczynił się do istotnego postępu w diagnostyce oraz monitorowaniu wielu schorzeń. Obrazy medyczne dostarczają szczegółowych informacji o budowie i funkcjonowaniu narządów, umożliwiając wczesne wykrycie patologii oraz dobór optymalnej terapii. Ze względu na złożoność i wielowymiarowość danych, ich prawidłowe przechowywanie, udostępnianie oraz analiza wymagają zastosowania specjalistycznych standardów i narzędzi.

Podstawowym standardem przechowywania i wymiany danych obrazowych w medycynie jest DICOM (Digital Imaging and Communications in Medicine). Format ten został opracowany w latach 80. XX wieku w celu ujednolicenia zapisu danych pochodzących z różnych urządzeń diagnostycznych. DICOM łączy w sobie zarówno obraz, jak i zestaw metadanych opisujących m.in. dane pacjenta, parametry badania, modalność, a także informacje dotyczące ustawień aparatury.

2. Algorytm diagnozowania skoliozy

2.1. Opis

Skolioza opisywana jest w literaturze medycznej jako jedno lub więcej nieprawidłowych bocznych skrzywień kręgosłupa z rotacją kręgów lub bez. Według Scoliosis Research Society skoliozę określa się jako skrzywienie kręgosłupa o kąt większy niż 10° . Na zdjęciu rentgenowskim kręgosłup osoby cierpiącej na skoliozę wygląda bardziej jak litera "S" lub "C" niż prosta linia. [1] Termin "skolioza" ma swoje korzenie w starożytnym słowie "skolios" (wygięty, skrzywiony) i został po raz pierwszy użyty przez Galena (130-201 rok naszej ery).[2]

Skoliozę można podzielić na typy: idiopatyczną, wrodzoną i nerwowo-mięśniową. Najczęstsza postać skoliozy czyli idiopatyczna skolioza młodzieńcza (AIS), ma nieznaną przyczynę co odzwierciedla termin "idiopatyczna". AIS jest zazwyczaj wykrywane w okresie dzieciństwa i dorostania, zwłaszcza w okresach szybkiego wzrostu. Skolioza wrodzona jest spowodowana nieprawidłowym rozwojem kręgosłupa w stadium embrionalnym, co może obejmować brak segmentacji kręgów, nieprawidłowy kształt lub nieprawidłową liczbę kręgów. Ten rodzaj skoliozy jest często związany z czynnikami genetycznymi i może współistnieć z innymi wadami wrodzonymi, dlatego zazwyczaj rozpoznaje się go po urodzeniu lub we wczesnym okresie niemowlęcym.[3] Skolioza nerwowo-mięśniowa jest wynikiem zaburzeń nerwowo-mięśniowych, które wpływają na mięśnie i nerwy odpowiedzialne za utrzymanie prawidłowego ułożenia kręgosłupa. Do najczęstszych przyczyn należą: porażenia mózgowie, dystrofia mięśniowa i urazy rdzenia kręgowego. [4]

Skolioza jest najczęstszym schorzeniem kręgosłupa wśród dzieci i młodzieży. Według różnych badań częstość występowania w tym wieku to aż od 0,47% do 5,2%. Stosunek kobiet do mężczyzn waha się od 1,5:1 do 3:1 i znacznie wzrasta wraz z wiekiem.[2]

Diagnoza skoliozy wymaga wieloetapowego podejścia łączącego badanie kliczne z diagnostyką obrazową. Istotne jest wczesne wykrycie i ocena stopnia zaawansowania choroby, szczególnie w przypadku AIS. Proces diagnostyczny rozpoczyna się od zebrania dokładnej historii pacjenta obejmującej:

- dynamikę wzrostu dziecka w ostatnim czasie,

- dynamikę wzrostu dziecka w ostatnim czasie,
- ból pleców,
- rodzinna historia skoliozy.

Test zgięcia Adama służy do wykrywania strukturalnych deformacji kręgosłupa, w szczególności rotacji kręgów i wynikającego z tego garbu żebrowego lub wypukłości lędźwiowej. Jest podstawową metodą przesiewową stosowaną zarówno przez lekarzy ortopedów, jak i fizjoterapeutów oraz w badaniach populacyjnych u dzieci i młodzieży. Test zgięcia jest bardzo czuły na deformacje rotacyjne, ale nie pozwala na ustalenie wartości kąta skrzywienia. Dlatego stanowi wstęp zarówno do oceny klinicznej skoliometrem, jak i do ewentualnej diagnostyki obrazowej.

Pomiar skoliozy skoliometrem stanowi uzupełnienie testu zgięcia Adama i pozwala na ilościową ocenę wielkości rotacji tułowia (Angle of Trunk Rotation – ATR). Badanie wykonuje się w pozycji pochylenia do przodu, przykładając skoliometr w linii wyrostków kolczystych na poziomie największej deformacji. Urządzenie rejestruje różnicę wysokości obu stron tułowia, co odzwierciedla stopień rotacji kręgów. Wartości ATR powyżej 5–7 stopni są sygnałem do pogłębionej diagnostyki, a powyżej 10 stopni zazwyczaj wymagają wykonania badania obrazowego, najczęściej RTG, wraz z oceną kąta Cobba. Pomiar skoliometrem jest szybki, nieinwazyjny i szeroko stosowany zarówno w badaniach przesiewowych, jak i w monitorowaniu progresji skrzywienia.[5]

Radiogram kręgosłupa stanowi podstawowe narzędzie obrazowe wykorzystywane w ocenie skoliozy, a szczególnie w ilościowej analizie deformacji czołowej metodą Cobba. Standardem jest wykonanie projekcji PA (tylnio-przedniej) całego kręgosłupa w pozycji stojącej, co umożliwia uwzględnienie obciążenia grawitacyjnego i realistyczną ocenę stopnia skrzywienia. Istotne jest zachowanie odpowiednich parametrów ekspozycji oraz minimalizacja artefaktów wynikających z rotacji ciała lub niewłaściwego ustawienia pacjenta. Mimo że badanie RTG jest dwuwymiarowe i niesie ograniczenia w ocenie rotacji osiowej, pozostaje metodą referencyjną w diagnostyce skoliozy ze względu na wysoką dostępność, powtarzalność oraz możliwość precyzyjnego wyznaczenia kąta skrzywienia.

Przed przystąpieniem do pomiaru kąta Cobba konieczna jest dokładna analiza obrazu RTG w celu wyznaczenia kręgów zaangażowanych w deformację. Najpierw identyfikuje się kręg szczytowy, czyli kręg o największym odchyleniu bocznym od osi pionowej. Następnie wyznacza się kręgi krańcowe górny i dolny - charakteryzujące się największym

nachyleniem płytek granicznych względem poziomu. Wybór tych struktur jest kluczowy, ponieważ stanowi punkt wyjścia dla dalszych konstrukcji geometrycznych pomiaru.

Pomiar kąta Cobba polega na konstrukcji prostych geometrycznych prowadzonych względem płytek granicznych kręgów krańcowych. Najpierw rysuje się linię styczną do górnej powierzchni kręgu krańcowego górnego oraz linię styczną do dolnej powierzchni kręgu krańcowego dolnego. Następnie prowadzi się prostopadłe do tych linii, które po przedłużeniu przecinają się, tworząc charakterystyczny kąt odpowiadający wielkości skrzywienia. W przypadku gdy linie płytkowe przecinają się w obrębie pola obrazu, dopuszczalne jest bezpośrednie mierzenie kąta między nimi. Pomiar powinien być wykonywany z zachowaniem jednolitej techniki, ponieważ metoda Cobba wykazuje pewien poziom zmienności obserwatora. Dla celów monitorowania progresji skoliozy kluczowe jest zatem stosowanie tej samej procedury pomiarowej, najlepiej przez tego samego obserwatora, oraz opieranie się na badaniach wykonanych w analogicznych warunkach ekspozycji i pozycjonowania.

Wartość kąta Cobba stanowi podstawowy parametr ilościowy determinujący rozpoznanie skoliozy, ocenę jej nasilenia oraz dobór strategii terapeutycznej. Kąt poniżej 10° traktuje się jako asymetrię tułowia, natomiast wartości równe lub przekraczające 10° stanowi kryterium rozpoznania skoliozy. Zakres $10-25^\circ$ zwykle kwalifikuje pacjenta do obserwacji i leczenia zachowawczego, natomiast skrzywienie $25-45^\circ$ u pacjentów rosnących stanowi wskazanie do leczenia gorsetowego. Deformacje przekraczające $45-50^\circ$ rozważa się w kontekście leczenia operacyjnego, zwłaszcza w przypadku progresji. Metoda Cobba odgrywa również istotną rolę w ocenie dynamiki skrzywienia - progresja o więcej niż 5° pomiędzy kolejnymi badaniami RTG uznawana jest za klicznie istotną. Dzięki swojej prostocie i wysokiej reprodukowalności parametr ten pozostaje podstawą planowania i monitorowania leczenia skoliozy we wszystkich postaciach.

2.2. Założenia funkcjonalne i nefunkcjonalne

W celu zrealizowania postawionego celu pracy zdefiniowano szereg wymagań funkcjonalnych oraz nefunkcjonalnych.

Wymagania funkcjonalne:

- **Obsługa wejściowych danych wolumetrycznych** – system musi umożliwiać wczytanie trójwymiarowych obrazów medycznych (mapy segmentacji) w standardzie

NIfTI[6] (.nii.gz), reprezentujący odcinek lędźwiowy kręgosłupa wraz z kanałem kręgowym.

- **Wyznaczenie linii środkowej kanału kręgowego** – algorytm musi wygenerować gładką krzywą reprezentującą przebieg kanału kręgowego w przestrzeni 3D.
- **Lokalna analiza geometrii kręgu** – dla każdego kręgu system wyznacza lokalny układ współrzędnych
- **Ekstrakcja przekrojów 2D i detekcja punktów charakterystycznych** - algorytm dokonuje próbkowania (resampling) wolumenu do płaszczyzny strzałkowej każdego kręgu
- **Wyznaczenie punktów charakterystycznych** – algorytm określa cztery narożne punkty trzonów kręgów
- **Automatyczny pomiar kąta Cobba** – system oblicza kąt Cobba pomiędzy dowolnymi parami kręgów oraz identyfikuje parę kręgów o największej deformacji.
- **Wizualizacja i eksport wyników** – system musi generować dane wynikowe i pośrednie w formacie umożliwiającym ich wizualną weryfikację przez lekarza (np. pliki znaczników JSON kompatybilne z oprogramowanie 3D Slicer), zawierające punkty, linie pomiarowe oraz wektory.


Wymagania niefunkcjonalne:

- **Odporność na nieciągłość danych** – algorytm powinien radzić sobie z przerwami w segmentacji kanału kręgowego
- **Powtarzalność wyników** – dla tych samych danych wejściowych algorytm musi zwracać zawsze ten sam wynik pomiarowy
- **Efektywność czasowa przetwarzania** – algorytm musi charakteryzować się niską złożonością obliczeniową, umożliwiając przetworzenie pojedynczego badania w czasie akceptowalnym klinicznie.
- **Interoperacyjność** – rozwiązanie powinno wykorzystywać otwarte standardy wymiany danych medycznych, co pozwala na łatwą integrację z istniejącymi narzędziami badawczymi i przeglądarkami DICOM.

Zdefiniowane powyżej wymagania stanowią podstawę do opracowania metodyki oraz implementacji algorytmu, które zostaną przedstawione w kolejnych rozdziałach pracy.

2.3. Metodka i opis algorytmu

W niniejszym rozdziale przedstawiono opis zaprojektowanego algorytmu. Proces przetwarzania danych podzielono na etapy: od wstępnego przetwarzania obrazu (preprocessing), poprzez ekstrakcję cech geometrycznych, aż po finalne obliczenia pomiarów wynikowych.




Rysunek 2.1: Ogólny potok przetwarzania danych dla algorytmu detekcji skoliozy

2.3.1. Wyznaczenie szkieletu kanału kręgowego

Pierwszym krokiem algorytmu jest wyznaczenie szkieletu kanału kręgowego. Metoda zaczyna się od połączenia trzech części segmentacji odpowiadającym kanałowi

kręgowemu, kanału kręgowego ('spinal_canal'), końskiego ogona ('cauda_equina') oraz worka oponowego ('dural_sac'), w jedną. W ten sposób obszar kanału kręgowego jest bardziej odporny na 'przerwy' w segmentacji, zwiększa obszar do późniejszego procesowania.

Następnym krokiem jest przekazanie złączonych etykiet do funkcji `skeletonize` z argumentem `method=lee` z pakietu `scikit-image` w celu wyznaczenie szkieletu kanału kręgowego.[7] Następnie za zwróconym zestawie pikseli (szkielecie) dokonano próbkowania (resamplingu) do przestrzeni wejściowego kanału kręgowego. Kolejnym krokiem jest przeiterowanie się przez całą długość wektora Z (wysokość) próbkowanego szkieletu kanału kręgowego z krokiem równym grubości warstwy przestrzeni i wyznaczenie punktów kanału kręgowego. Niekiedy segmentacja kanału kręgowego mimo połączenia trzech etykiet dalej jest niepełna bądź nieciągła, w tym przypadku wykrywane są brakujące fragmenty i uzupełniane.



Rysunek 2.2: Wyznaczone punkty kanału kręgowego przed uzupełnieniem brakujących fragmentów.

Algorytm odporny jest na brakujące fragmenty segmentacji, które mogą wynikać z lokalnie słabego sygnału danych wejściowych, artefaktów obrazowania, lub błędu narzędzia segmentującego. Aby umożliwić wyznaczenie ciągłej krzywizny kręgosłupa niezbędnej do pomiaru kąta Cobba, zastosowano algorytm aproksymacji brakujących danych. Zaimplementowana funkcja `approximate` realizuje zadanie uzupełniania brakujących danych przestrzennych (ubytków w segmentacji) przy wykorzystaniu interpolacji funkcjami sklejanymi trzeciego stopnia (ang. *Cubic Spline Interpolation*).[8]

Przed przystąpieniem do aproksymacji kształtu kanału kręgowego, konieczna jest identyfikacja miejsc, w których proces segmentacji nie zwrócił wyników (tzw. luk w danych). W tym celu opracowano algorytm analizy dystrybucji punktów wzdłuż osi podłużnej (Z) kręgosłupa.

Niech $P = \{p_0, p_1, \dots, p_N\}$ będzie zbiorem uporządkowanych punktów (centroidów)

wykrytych w procesie wstępnym. Algorytm iteruje przez pary sąsiednich punktów (p_{i-1}, p_i) , obliczając dystans wzdłuż osi Z:

$$\Delta z_i = |z_i - z_{i-1}| \quad (2.1)$$

Zdefiniowano parametry systemowe:

- h_{step} – oczekiwany krok próbkowania, odpowiadający grubości warstwy badawczej (Slice Thickness) lub odstępowi między skanami (w implementacji przyjęto $h_{step} = 3.2$ mm).
- T_{thresh} – próg detekcji błędu, definiujący minimalną odległość uznawaną za lukę w danych.

Jeśli wyznaczona odległość Δz_i przekracza próg T_{thresh} , algorytm klasyfikuje ten obszar jako ubytek segmentacji. Liczba brakujących warstw k_{miss} estymowana jest na podstawie ilorazu całkowitego odległości i oczekiwanego kroku:

$$k_{miss} = \left\lfloor \frac{\Delta z_i}{h_{step}} \right\rfloor \quad (2.2)$$

Na podstawie wartości k_{miss} , algorytm buduje nowe przestrzenie indeksów:

1. **Indeksy zachowane (I_{rem}):** odpowiadające punktom poprawnie wykrytym.
2. **Indeksy brakujące (I_{miss}):** wirtualne znaczniki miejsc, które wymagają uzupełnienia.

Ze względu na złożoną geometrię kręgosłupa w przestrzeni 3D, linia środkowa kanału kręgowego nie może być opisana jako prosta funkcja jednej zmiennej. Zamiast tego zdefiniowano ją jako krzywą wektorową $C(t)$, zależną od znormalizowanego parametru t :

$$C(t) = \begin{bmatrix} x(t) \\ y(t) \\ z(t) \end{bmatrix}, \quad \text{dla } t \in [0, 1] \quad (2.3)$$

gdzie parametr t reprezentuje znormalizowaną pozycję wzdłuż długiej osi kręgosłupa. W implementacji parametr ten uzyskano poprzez liniowe mapowanie indeksów dostępnych warstw (`np.linspace`).

Problem interpolacji 3D rozłożono na trzy niezależne podproblemy jednowymiarowe. Dla każdej współrzędnej przestrzennej ($\xi \in \{x, y, z\}$) skonstruowano funkcję sklejaną $S_\xi(t)$. W

każdym podprzedziale $[t_i, t_{i+1}]$ funkcja ta jest wielomianem trzeciego stopnia:

$$S_\xi(t) = a_i + b_i(t - t_i) + c_i(t - t_i)^2 + d_i(t - t_i)^3 \quad (2.4)$$

Współczynniki a_i, b_i, c_i, d_i wyznaczono tak, aby zapewnić ciągłość funkcji $S(t)$ oraz jej pierwszej $S'(t)$ i drugiej $S''(t)$ pochodnej w węzłach interpolacji.


W kodzie zastosowano naturalne warunki brzegowe (`bc_type='natural'`), co jest kluczowe dla uniknięcia nienaturalnych wygięć krzywej na krańcach badanego odcinka. Matematycznie oznacza to zerowanie się drugiej pochodnej (krzywizny) na końcach przedziału:

$$S''_\xi(0) = 0 \quad \text{oraz} \quad S''_\xi(1) = 0 \quad (2.5)$$

Dla każdego brakującego fragmentu danych o indeksie k_{miss} , wyznaczono odpowiadającą mu wartość parametru t_{miss} poprzez interpolację liniową znanych indeksów. Ostateczne współrzędne punktu zrekonstruowanego P_{rec} obliczono jako:

$$P_{rec} = (S_x(t_{miss}), S_y(t_{miss}), S_z(t_{miss})) \quad (2.6)$$

Tak uzyskane punkty scalono z danymi oryginalnymi i posortowano, uzyskując ciągłą reprezentację geometryczną kanału kręgowego, co umożliwia dalsze precyzyjne pomiary kątów skrzywienia.



Rysunek 2.3: Wypełnione luki segmentacji kanału kręgowego

Po etapie rekonstrukcji ubytków, zbiór punktów reprezentujących kanał kręgowy posiada ciągłość, jednak dystrybucja punktów w przestrzeni może być niejednorodna. Aby zapewnić stałą rozdzielczość przestrzenną niezbędną do precyzyjnych pomiarów geometrycznych, przeprowadzono proces reparametryzacji i zagęszczenia próbkowania.

Algorytm realizowany jest w trzech krokach:

W pierwszej kolejności usuwane są punkty, które dublują się lub znajdują się w odległości mniejszej niż błąd numeryczny ($\epsilon = 10^{-6}$). Jest to krok niezbędny dla stabilności numerycznej algorytmów interpolacyjnych, które wymagają ściśle rosnącego argumentu funkcji.

$$P_{filtered} = \{p_i \in P : \|p_i - p_{i-1}\| > \epsilon\} \quad (2.7)$$

W przeciwieństwie do poprzedniego etapu, gdzie parametrem była oś Z , tutaj

zastosowano naturalną parametryzację krzywej w przestrzeni 3D. Zdefiniowano parametr s , będący skumulowaną długością euklidesową wzdłuż łamanej łączącej kolejne punkty (ang. *cumulative chord length*):

$$s_0 = 0, \quad s_k = \sum_{i=1}^k \|p_i - p_{i-1}\| \quad (2.8)$$

Dzięki temu dziedziną funkcji interpolującej staje się rzeczywista długość krzywej, a nie współrzędna kartezjańska, co pozwala na poprawne odwzorowanie pętli i silnych skrzywień niebędących funkcjami w sensie matematycznym względem jednej osi.


Na podstawie obliczonych odległości s , skonstruowano nowe funkcje sklejące trzeciego stopnia $C(s)$ dla każdej współrzędnej. Następnie dokonano ponownego próbkowania (resampling) krzywej, generując nowy wektor parametrów s'_j rozmieszczonych w idealnie równych odstępach:

$$s'_j = j \cdot \frac{s_{max}}{M}, \quad \text{dla } j = 0, \dots, M \quad (2.9)$$

gdzie M to nowa liczba próbek, ustalona jako dwukrotność liczby punktów wejściowych ($M = 2 \cdot N$).

W rezultacie uzyskano zbiór punktów $P_{new} = C(s')$, który charakteryzuje się:

- **Większą gęstością:** dwukrotne zagęszczenie pozwala na precyzyjniejsze uchwycenie lokalnych zmian krzywizny.
- **Jednorodnością:** stały krok przestrzenny między punktami jest kluczowy dla algorytmów różniczkowych obliczających wektory styczne w kolejnych etapach analizy.



Rysunek 2.4: Jednorodne zagęszczenie punktów kanału kręgowego

Po uzyskaniu kanału kręgowego z równomiernym rozmieszczeniem punktów następnym krokiem jest wyznaczenie lokalnego układu współrzędnych każdego kręgu w celu wyeliminowania błędów pomiarowych wynikających z naturalnej krzywizny kręgosłupa (lordozy lędźwiowej) oraz potencjalnej rotacji kręgów.

Pierwszym etapem analizy geometrycznej każdego kręgu jest wyznaczenie jego środka masy (centroidu). Dla każdej odizolowanej etykiety kręgu V obliczane są statystyki kształtu przy użyciu filtru *LabelShapeStatisticsImageFilter*. Centroid trzonu kręgu C_{body} jest wyznaczany jako średnia arytmetyczna współrzędnych wszystkich wokseli należących do danej etykiety:

$$C_{body} = \frac{1}{N} \sum_{i=1}^N P_i \quad (2.10)$$

gdzie P_i oznacza wektor współrzędnych $[x, y, z]^T$ i -tego woksela, należącego do kręgu, a

N jest całkowitą liczbą wokseli składającą się na tą strukturę.

W celu wyznaczenia lokalnej orientacji, kręgi musi zostać odniesiony do przebiegu kanału kręgowego. Realizuje to funkcja `find_closest_i`, która przeszukuje zbiór punktów kanału $S = \{s_1, s_2, \dots, s_m\}$ wyznaczonych we wcześniejszym etapie (poprzez funkcję `to_do`) szukając punktu o minimalnej odległości euklidesowej od centroidu kręgu:

$$i^* = \arg \min_{i \in \{1, \dots, m\}} \|s_i - \mathbf{C}_{\text{body}}\|^2 \quad (2.11)$$

Zastosowanie kwadratu odległości pozwala na przyspieszenie obliczeń poprzez uniknięcie operacji pierwiastkowania, nie zmieniając przy tym położenia minimum funkcji.

Mając wyznaczony punkt odniesienia na kanale kręgowym, algorytm definiuje lokalne sąsiedztwo punktów (okno o rozmiarze 21 punktów), aby znaleźć lokalną krzywiznę. Orientacja pionowa y_{vec} jest wyznaczana przy użyciu analizy głównych składowych (ang. *Principal Component Analysis* – PCA)[9], z pakietu `sklearn.decomposition`. Dla lokalnego podzbioru punktów S_{local} obliczana jest macierz kowariancji:


$$\text{Cov}(S_{local}) = \frac{1}{n-1} \sum_{j=1}^n (s_j - \bar{s})(s_j - \bar{s})^T \quad (2.12)$$

gdzie $\bar{s}$ jest wartością średnią pozycji punktów w oknie. Wektor orientacji y_{vec} odpowiada pierwszemu wektorowi osobliwemu (ang. *principal vector*), który wskazuje kierunek największej wariancji zbioru punktów, czyli w tym przypadku kierunek styczny do kanału kręgowego. Wyznaczony wektor jest normalizowany do jedności:

$$\hat{y}_{vec} = \frac{\vec{y}_{vec}}{|\vec{y}_{vec}|} \quad (2.13)$$

Ostatnim krokiem jest zapewnienie spójności zwrotu wektora. W medycznym układzie współrzędnych przyjęto konwencję, w której oś Z rośnie w kierunku czaszkowym (Superior). Algorytm sprawdza składową z wektora i w razie potrzeby dokonuje jego inwersji, aby wektor zawsze wskazywał kierunek górny:

$$\vec{y} = \begin{cases} -\hat{y}_{vec} & \text{jeżeli } (\hat{y}_{vec} \cdot [0, 0, 1]^T) > 0 \\ \hat{y}_{vec} & \text{w przeciwnym razie} \end{cases} \quad (2.14)$$




Rysunek 2.5: Wektor $\hat{y}_{final}$ dla jednego z kręgów (L2) wraz z lokalnymi punktami kanału kręgowego

Po ustaleniu orientacji pionowej kręgu, algorytm przystępuje do wyznaczenia wektora z , który w lokalnym układzie współrzędnych reprezentuje oś przednio-tylną (*anterior-posterior*). Wektor $\vec{z}_{raw}$ jest definiowany jako różnica położeń między wcześniej obliczonym, w równaniu (2.10), centroidem trzonu kręgu C_{body} , a również obliczonym w poprzedniej części algorytmu najbliższym punktem od trzonu kręgu do kanału kręgowego (2.11).

$$\vec{z}_{raw} = P_{i^x} - C_{body} \quad (2.15)$$

Wyznaczony wektor podobnie jak w (2.13) normalizowany jest do jedności:

$$\vec{z} = \frac{\vec{z}_{raw}}{|\vec{z}_{raw}|} \quad (2.16)$$



Rysunek 2.6: Wektor $\vec{z}$ dla jednego z kręgów (L2) wraz z lokalnymi punktami kanału kręgowego


Ostatnim krokiem, mając wyznaczone dwa wektory jednostkowe $\vec{y}$ ((2.13), styczny do kanału kręgowego w sąsiedztwie kręgu) oraz $\vec{z}$ ((2.16), łączący środek trzony z kanałem kręgowym), jest wyznaczenie trzeciego wektora $\vec{x}$. Wektor ten odpowiada osi boczno-przyśrodkowej (ang. *medial-lateral*), czyli orientacji lewo-prawo.

Aby zapewnić idealną prostopadłość wszystkich osi, co jest niezbędne do poprawnego przepróbkowania obrazu bez wprowadzania deformacji geometrycznych, zastosowano operację iloczynu wektorowego. Wektor $\vec{x}_{raw}$ jest wyznaczony jako iloczyn wektorowy osi grzbietowej oraz pionowej.

$$\vec{x}_{raw} = \vec{z} \times \vec{y} \quad (2.17)$$

Zgodnie z definicją iloczynu wektorowego, wynikowy wektor $\vec{x}_{raw}$ jest prostopadły do obu wektorów wejściowych, co fizycznie odpowiada kierunkowi poprzecznemu względem płaszczyzny strzałkowej kręgu. Poprzednie jak w przypadku poprzednich osi, wektor $\vec{x}_{raw}$ zostaje poddany normalizacji, aby stał się wektorem jednostkowym.

$$\vec{x} = \frac{\vec{x}_{raw}}{|\vec{x}_{raw}|} \quad (2.18)$$



Rysunek 2.7: Wektor $\vec{x}$ dla jednego z kręgów (L2), wraz z pozostałymi wektorami tworzącymi lokalny układ współrzędnych.

Możemy tutaj opisać re-ortogonalizacją

$$x_v ec = np.cross(z_v ec, y_v ec), x_v ec /= np.linalg.norm(x_v ec)$$

Wyznaczenie bazy ortonormalnej $\{\vec{x}, \vec{y}, \vec{z}\}$ pozwala na uniezależnienie procesu analizy od globalnego układu współrzędnych skanera DICOM. Następnym krokiem algorytmu jest wykorzystanie tej macierzy rotacji do przeprowadzenia operacji przepróbkowania (ang. *resampling*). Proces ten ma na celu przekształcenie trójwymiarowej chmury wokseli w serię zorientowanych diagnostycznie obrazów dwuwymiarowych. Takie podejście pozwala na sprowadzenie złożonej geometrii przestrzennej kręgosłupa do płaszczyzny pomiarowej, na której możliwe jest zastosowanie klasycznych metod wizji komputerowej. Przed przystąpieniem do przepróbkowania obrazu, konieczne jest wyznaczenie fizycznego punktu początkowego nowej siatki obrazu (ang. *origin*). Punkt ten, oznaczony w algorytmie jako *anchor*, jest przesunięty względem centroidu kręgu C_{body} , aby zapewnić centralne położenie struktury na wynikowym obrazie o wymiarach 500x500 pikseli.

$$P_{anchor} = C_{body} - 50\vec{x} - 50\vec{y} \quad (2.19)$$

Przesunięcie o 50mm w kierunkach osi $\vec{x}$ i $\vec{y}$ pozycjonuje punkt początkowy tak, aby trzon

kręgu znajdował się w polu widzenia algorytmu detekcji konturów. Aby przekształcić dane z globalnej siatki wokseli do lokalnej płaszczyzny, konstruowana jest macierz kierunkowa (ang. *Direction Matrix*) $\mathbf{D}$. Składa się ona z wektorów bazowych lokalnego układu współrzędnych.

$$\mathbf{D} = \begin{bmatrix} x_0 & y_0 & z_0 \\ x_1 & y_1 & z_1 \\ x_2 & y_2 & z_2 \end{bmatrix} \quad (2.20)$$

gdzie $[x_i, y_i, z_i]^T$ są składowymi znormalizowanych wektorów lokalnej bazy.


Właściwa ekstrakcja przekroju realizowana jest przy użyciu filtru *ResampleImageFilter* z biblioteki SimpleITK. Parametry wyjściowe obrazu zdefiniowano następująco:

- **Rozmiar:** 500×500 pikseli.
- **Rozdzielczość (Spacing):** 0.5×0.5 mm na piksel, co pozwala na zachowanie wysokiej precyzji pomiarowej.
- **Interpolacja:** Metoda najbliższego sąsiada (*Nearest Neighbor*).

Wybór interpolacji typu *Nearest Neighbor* jest krytyczny, ponieważ przetwarzane dane wejściowe są mapą etykiet (segmentacją). Zastosowanie interpolacji liniowej doprowadziłoby do powstania nieistniejących wartości pośrednich na granicach struktur, co uniemożliwiłoby poprawną detekcję krawędzi binarnych. Dla każdego piksela (u, v) na wynikowym obrazie 2D, jego współrzędne w fizycznej przestrzeni 3D (P_{phys}) obliczane są zgodnie z przekształceniem afinicznym:

$$P_{phys} = \mathbf{D} \cdot \begin{bmatrix} u \cdot s_u & v \cdot s_v & 0 \end{bmatrix} \quad (2.21)$$

gdzie s_u, s_v to wartości odstępów między pikselami (*spacing*). Wynikiem tej operacji jest obraz *resampled*, który stanowi bazę dla kolejnego etapu — ekstrakcji konturu trzonu kręgu.



Rysunek 2.8: Wizualizacja trójwymiarowa pojedynczego kręgu lędźwiowego wraz z nałożoną lokalną płaszczyzną przekroju strzałkowego, wyznaczoną na podstawie bazy ortonormalnej $\{\vec{x}, \vec{y}, \vec{z}\}$



Rysunek 2.9: Wizualizacja dwuwymiarowa pojedynczego kręgu lędźwiowego na lokalnej płaszczyźnie przekroju strzałkowego.

Po uzyskaniu zorientowanego lokalnie przekroju 2D, algorytm przystępuje do kluczowego etapu analizy, którego celem jest wyznaczenie czterech punktów narożnych trzonu kręgu. Punkty te definiują blaszki graniczne (górną i dolną), stanowiąc bezpośrednią podstawę do obliczenia kąta Cobba. Do wyznaczenia tych struktur użyte będą metody z biblioteki OpenCV dla Pythona cv2[10].

W celu wyeliminowania drobnych artefaktów powstałych na etapie segmentacji, obraz

poddawany jest operacji morfologicznego otwarcia (ang. *morphological opening*, z biblioteki `cv2.morphologyEx(image, cv2.MORPH_OPEN, np.ones((5, 5), np.uint8), iterations=2))`[11]. Wykorzystano element strukturalny o rozmiarze 5x5 pixeli co pozwala na wygładzenie brzegów struktury przy jednoczesnym zachowaniu jej pierwotnego kształtu oraz dwie iteracje, aby wyeliminować szum oraz drobne struktury niebędące częścią trzonu:

$$I_{cleaned} = (I_{flat} \circ B) \quad (2.22)$$

gdzie B to kwadratowa macierz binarna, a symbol $\circ$ oznacza operację otwarcia.

Następnie, w celu precyzyjnego wyznaczenia granic trzonu, zastosowano detektor krawędzi Canny'ego[12] (z biblioteki `cv2.Canny(image, 0, 1)`, gdzie 0 i 1 to wartości graniczne dla obrazu binarnego trzonu kręgu i tła między którymi wyznaczona będzie granica). Pozwala on na zredukowanie informacji o całej masie kręgu do zbioru punktów brzegowych o szerokości jednego piksela.

Z wykrytych krawędzi ekstrahowany jest kontur zewnętrzny (z biblioteki `cv2.findContours(image, cv2.RETR_EXTERNAL, cv2.CHAIN_APPROX_SIMPLE)` z parametrami `RETR_EXTERNAL` do wyznaczenia tylko zewnętrznych konturów, oraz `CHAIN_APPROX_SIMPLE` do wykrycia tylko niezbędnych punktów).

Aby zniwelować wpływ lokalnych nierówności powierzchni trzonu kręgowego, algorytm wyznacza otoczkę wypukłą (ang. *Convex Hull*) metodą z biblioteki `cv2.convexHull(contours)`.

Następnie zastosowano algorytm **Douglasa-Peuckera**[13] (metoda `cv2.approxPolyDP(hull, 0.01, True)` - gdzie 0.01 to dokładność - im mniejsza tym bardziej wynikowy wielokąt przypomina oryginał, a trzeci parametr informuje, że krzywa ma być zamkniętą pętlą), który dokonuje aproksymacji wielokątowej konturu. Proces ten redukuje liczbę punktów opisujących kształt, pozostawiając jedynie te najbardziej istotne z punktu widzenia geometrii struktury.

Ostatnim etapem analizy geometrycznej jest selekcja czterech kluczowych punktów narożnych z uzyskanego wielokąta aproksymacyjnego. W tym celu zaimplementowano algorytm oparty na analizie sumy i różnicy współrzędnych $[x, y]$ punktów konturu, co pozwala na ich jednoznaczną klasyfikację topologiczną (lewy górny, prawy górny, lewy dolny, prawy dolny).


Lewy górny róg (P_{TL}) oraz prawy dolny róg (P_{BR}) są identyfikowane poprzez

minimalizację i maksymalizację sumy współrzędnych:


$$P_{TL} = \operatorname{argmin}(x_i + y_i), P_{BR} = \operatorname{argmax}(x_i + y_i) \quad (2.23)$$

Prawy górny róg (P_{TR}) oraz lewy dolny róg (P_{BL}) są wyznaczone poprzez analizę różnicy współrzędnych:

$$P_{TR} = \operatorname{argmax}(x_i - y_i), P_{BL} = \operatorname{argmin}(x_i - y_i) \quad (2.24)$$



Rysunek 2.10: Wizualizacja wyznaczonej krawędzi pojedynczego kręgu lędźwiowego na lokalnej płaszczyźnie przekroju strzałkowego.




Rysunek 2.11: Wizualizacja etapów ekstrakcji cech geometrycznych trzonu.

Wyznaczone punkty narożne reprezentują położenie struktur anatomicznych w układzie współrzędnych macierzy pikseli. Ze względu na fakt, że analiza obrazów DICOM wymaga uzyskania wyników o znaczeniu klinicznym, niezbędne jest przejście z jednostek bezwzględnych (pikseli) na jednostki fizyczne (milimetry). Następnym etapem algorytmu jest zatem transformacja uzyskanych współrzędnych do trójwymiarowej przestrzeni lokalnego przekroju anatomicznego, zdefiniowanego we wcześniejszych etapach algorytmu:

$$P_{\text{local},3D} = \mathbf{T}_{\text{plane}} \cdot P_{\text{index}} \quad (2.25)$$

gdzie T_{plane} to macierz transformacji zdefiniowana dla zorientowanego lokalnie obrazu

przekroju (2.20). Operacja ta, zaimplementowana jest jako `TransformContinuousIndexToPhysicalPoint` z biblioteki `SimpleITK`[14]. Dzięki temu uzyskane punkty P_{start_top} , P_{end_top} , P_{start_bot} , P_{end_bot} posiadają współrzędne wyrażone w milimetrach, ale są one ściśle zablokowane na płaszczyźnie, która reprezentuje anatomię danego kręgu.



Rysunek 2.12: Przestrzenna wizualizacja wyników ekstrakcji punktów narożnych trzonu kręgu w lokalnym układzie współrzędnych płaszczyzny przekroju. Widoczne dopasowanie punktów do krawędzi struktury anatomicznej po transformacji z układu 2D do przestrzeni 3D.

Po wyznaczeniu punktów narożnych dla każdego kręgu, algorytm przystępuje do finalnej fazy: wyznaczenia wspólnej płaszczyzny dla analizowanych par kręgów oraz obliczenia finalnej wartości kąta skrzywienia. Ze względu na to, że kręgosłup w skoliozie ulega rotacji w trzech płaszczyznach, bezpośrednie rzutowanie punktów na standardowe płaszczyzny układu współrzędnych pacjenta (np. czołową) mogłoby prowadzić do niepoprawnego wyliczenia kąta. Algorytm wykorzystuje metodę SVD (ang. *Singular Value Decomposition*) do znalezienia płaszczyzny najlepiej dopasowanej do zbioru punktów narożnych analizowanej pary kręgów (górnego i dolnego). Proces rozpoczyna się od wyznaczenia centroidu (środka geometrycznego) chmury punktów:

$$\bar{p} = 1/n \sum_{i=1}^n p_i \quad (2.26)$$

Następnie dokonuje się centrowania danych poprzez odjęcie centroidu od każdego punktu:

$$X_i = p_i - \bar{p} \quad (2.27)$$


Zcentrowane punkty tworzą macierz $A \in \mathbb{R}^{n \times 3}$). Dekompozycja SVD macierzy A zadana

jest wzorem:

$$A = U \Sigma V^T \quad (2.28)$$

gdzie V^T jest macierzą ortogonalną, której wiersze są wektorami własnymi macierzy kowariancji $A^T A$. Wektor normalny n szukanej płaszczyzny odpowiada wierszowi macierzy V^T , który jest związany z najmniejszą własnością osobliwą w macierzy Σ . Wektor ten wskazuje kierunek, w którym wariancja danych jest najmniejsza, co matematycznie definiuje kierunek normalny do płaszczyzny najlepiej dopasowanej w sensie najmniejszych kwadratów odległości ortogonalnych.

Mając wyznaczony centroid $\bar{p}$ (pełniący rolę punktu zakotwiczenia płaszczyzny) oraz znormalizowany wektor normalny n , algorytm dokonuje rzutowania każdego punktu p na płaszczyznę. Dzięki temu zabiegowi, wszystkie punkty narożne analizowanej pary kręgów zostają sprowadzone do wspólnego układu współrzędnych 2D (zakotwiczonego w 3D), co niweluje błędy i pozwala na poprawną implementację klinicznej definicji kąta Cobba.



Rysunek 2.13: Przestrzenna wizualizacja wyników ekstrakcji punktów narożnych trzonu kręgu w lokalnym układzie współrzędnych płaszczyzny przekroju. Widoczne dopasowanie punktów do krawędzi struktury anatomicznej po transformacji z układu 2D do przestrzeni 3D.

Po rzutowaniu punktów na optymalną płaszczyznę, algorytm implementuje funkcję `cobb_angle`, której zadaniem jest wyznaczenie kąta pomiędzy wektorami reprezentującymi krawędzie kręgów granicznych oraz określenie orientacji skrzywienia (lewo- lub prawostronne). Dla wybranej pary kręgów definiowane są dwa wektory kierunkowe u (wektor krawędzi górnej kręgu górnego) oraz l (wektor krawędzi dolnej kręgu dolnego). Zgodnie z geometryczną implementacją metody Cobba, kąt skrzywienia α odpowiada kątowi przecięcia prostych zawierających te wektory. Wartość kąta wyznaczana jest przy użyciu iloczynu skalarnego:

$$\begin{aligned}\vec{v}_1 \cdot \vec{v}_2 &= x_1x_2 + y_1y_2 \\ \|\vec{v}_1\| &= \sqrt{x_1^2 + y_1^2}, \quad \|\vec{v}_2\| = \sqrt{x_2^2 + y_2^2} \\ \alpha &= \arccos\left(\frac{\vec{v}_1 \cdot \vec{v}_2}{\|\vec{v}_1\| \|\vec{v}_2\|}\right) \cdot \frac{180^\circ}{\pi}\end{aligned}\tag{2.29}$$

Bibliografia

- [1] Scoliosis Research Society.
<https://www.srs.org/Patients/Conditions/Scoliosis>. data dostępu: 7 grudnia 2025.
- [2]
1. Konieczny MR, Senyurt H, Krauspe R. Epidemiology of adolescent idiopathic scoliosis. *Journ*
<https://doi.org/10.1007/s11832-012-0457-4>. data dostępu: 26 listopada 2025.
- [3]
Li M, Nie Q, Liu J, Jiang Z. Prevalence of scoliosis in children and adolescents: a systematic rev
<https://pmc.ncbi.nlm.nih.gov/articles/PMC11300313/>. data dostępu: 7 grudnia 2024.
- [4] Neuromuscular Scoliosis - Yale Medicine. <https://www.yalemedicine.org/clinical-keywords/neuromuscular-scoliosis>. data dostępu: 26 listopada 2025.
- [5] Popraw autorów tej bibliografii. <https://pimr.pl/assets/pdf/artykuly/294-303-paediatrics-family-medicine-3-2024-czaprowski-ang-pdf.pdf>. data dostępu: 5 grudnia 2025.
- [6] NiftI. <https://nifti.nimh.nih.gov>. data dostępu: 7 grudnia 2024.
- [7] scikit-image, skeletonize.
<https://scikit-image.org/docs/0.25.x/api/skimage.morphology.html>. data dostępu: 7 grudnia 2024.
- [8] Cubic Spline Interpolation. https://en.wikiversity.org/wiki/Cubic_Spline_Interpolation. data dostępu: 7 grudnia 2024.
- [9] PCA. <https://stable/modules/generated/sklearn.decomposition.PCA.html>. data dostępu: 7 grudnia 2024.
- [10] OpenCV. <https://opencv.org>. data dostępu: 7 grudnia 2025.

- [11] Otwarcie morfologiczne - poszukaj może znajdziesz lepszy link. <https://micro.magnet.fsu.edu/primer/digitalimaging/russ/erosiondilation.html>. data dostępu: 7 grudnia 2024.
- [12] Filtr Canny. https://docs.opencv.org/4.x/da/d22/tutorial_py_canny.html. data dostępu: 7 grudnia 2024.
- [13] Douglas-Peucker. <https://cartography-playground.gitlab.io/playgrounds/douglas-peucker-algorithm/>. data dostępu: 7 grudnia 2025.
- [14] SimpleITK. <https://simpleitk.org>. data dostępu: 7 grudnia 2025.